

Modelowanie zdolności kredytowej

Agenda

- Wprowadzenie
- Hipotezy badawcze
- Przygotowanie danych
- Eksploracyjna analiza danych
- Modele
 - Regresja logistyczna
 - Drzewo decyzyjne
 - Las losowy
 - Support Vector Machine
- Porównanie wyników
- Zysk z modeli
- Podsumowanie

Wprowadzenie

Problem decyzyjny polega na klasyfikacji klientów banku względem ryzyka niespłacenia zobowiązania kredytowego, wykorzystując informacje opisujące ich sytuację finansową, historię kredytową oraz parametry wnioskowanego kredytu.


Głównym celem projektu jest ustalenie, w jakim stopniu dane dotyczące klientów pozwalają skutecznie rozróżnić osoby o podwyższonym ryzyku defaultu od klientów terminowo spłacających swoje zobowiązania.

Hipotezy badawcze

1. Klienci o wyższym stosunku kwoty kredytu do dochodu charakteryzują się wyższym prawdopodobieństwem defaultu.
2. Historia wcześniejszego defaultu oraz niższa ocena kredytowa klienta są jednymi z najsilniejszych predyktorów ryzyka niespłacenia zobowiązania.

Przygotowanie danych


- I. Usunięto **165 zduplikowanych obserwacji**
- II. Usunięto obserwacje zawierające **brakujące wartości**
 - 1) person_emp_length – 895 obserwacji (2,75%)
 - 2) loan_int_rate – 3116 obserwacji (9,56%)



Przygotowanie danych

III. Zweryfikowano **dane odstające** oraz usunięto obserwacje z:



- 1) dochodem > 2,5 mln,
- 2) stażem pracy > 50 lat



Przygotowanie danych

IV. Zweryfikowano **poprawność danych** oraz usunięto obserwacje z:


- 1) wiekiem > 100 lat
- 2) stażem pracy przekraczającym wiek-15 lat



Przygotowanie danych

V. Łącznie usunięto 6 obserwacji błędnych i odstających

VI. Ostateczny zbiór danych zawiera 28 495 obserwacji i 12 zmiennych




Eksploracyjna analiza danych

Kod zmiennej	Opis zmiennej	Typ zmiennej	Wartości zmiennej
loan_grade	Ocena (rating) kredytu	kategoryczna	A - 9344 (32,79%) B - 9092 (31,91%) C - 5680 (19,93%) D - 3242 (11,38%) E - 869 (3,05%) F - 209 (0,73%) G - 59 (0,21%)
loan_amnt	Kwota wnioskowanego lub przyznanego kredytu	numeryczna	Minimum: 500 Maksimum: 35000 Średnia: 9657,37 Mediana: 8000 Odchylenie standardowe: 6327,71
loan_int_rate	Roczne oprocentowanie kredytu	numeryczna	Minimum: 5,42 Maksimum: 23,22 Średnia: 11,05 Mediana: 10,99 Odchylenie standardowe: 3,23
default	Status niewypłacalności kredytobiorcy (zmienna docelowa)	numeryczna	Minimum: 0 Maksimum: 1 Średnia: 0,22 Mediana: 0 Odchylenie standardowe: 0,41
loan_percent_income	Udział kwoty kredytu w dochodzie kredytobiorcy	numeryczna	Minimum: 0 Maksimum: 0,83 Średnia: 0,17 Mediana: 0,15 Odchylenie standardowe: 0,11
hist_default_in_past	Informacja o wystąpieniu defaultu w przeszłości	numeryczna	Minimum: 0 Maksimum: 1 Średnia: 0,18 Mediana: 0 Odchylenie standardowe: 0,38
hist_years	Długość historii kredytowej kredytobiorcy (w latach)	numeryczna	Minimum: 2 Maksimum: 30 Średnia: 5,80 Mediana: 4 Odchylenie standardowe: 4,04


Kod zmiennej	Opis zmiennej	Typ zmiennej	Wartości zmiennej
person_age	Wiek kredytobiorcy	numeryczna	Minimum: 20 Maksimum: 84 Średnia: 27,72 Mediana: 26 Odchylenie standardowe: 6,18
person_income	Roczny dochód netto kredytobiorcy	numeryczna	Minimum: 4000 Maksimum: 2039784 Średnia: 66430 Mediana: 56000 Odchylenie standardowe: 51514
person_home_ownership	Status własności nieruchomości kredytobiorcy	kategoryczna	RENT - 14495 (50,87%) MORTGAGE - 11733 (41,18%) OWN - 2174 (7,63%) OTHER - 93 (0,33%)
person_emp_length	Długość historii zatrudnienia kredytobiorcy (w latach)	numeryczna	Minimum: 0 Maksimum: 41 Średnia: 4,78 Mediana: 4 Odchylenie standardowe: 4,04
loan_intent	Cel przeznaczenia kredytu	kategoryczna	EDUCATION - 5668 (19,89%) MEDICAL - 5269 (18,49%) VENTURE - 4967 (17,43%) PERSONAL - 4857 (17,05%) DEBTCONSOLIDATION - 4547 (15,96%) HOMEIMPROVEMENT - 3187 (11,18%)

Eksploracyjna analiza danych



Struktura wg Wystąpienia defaultu w przeszłości



Struktura wg Statusu własności mieszkania




Eksploracyjna analiza danych




Eksploracyjna analiza danych

Rozkład wieku




Rozkład dochodu




Eksploracyjna analiza danych

Rozkład stażu pracy




Rozkład kwoty kredytu




Eksploracyjna analiza danych


Rozkład oprocentowania kredytu



Rozkład udziału kredytu w dochodzie




Eksploracyjna analiza danych




Eksploracyjna analiza danych

Struktura defaultu według oceny kredytu




Struktura defaultu według udziału kredytu w dochodzie




Eksploracyjna analiza danych

Struktura defaultu według dochodu kredytobiorcy




Struktura defaultu według kwoty kredytu



Eksploracyjna analiza danych


Korelacja zmiennych ze zmienną default



Regresja logistyczna

Grid Search z Walidacją Krzyżową (5-Fold CV):

- Regularyzacja Lasso (L1) vs Ridge (L2) w ramach ElasticNet
- Solver: 'Saga' - stochastyczny algorytm optymalizacyjny dla ElasticNet
- Korekta wag dla niezbalansowanych klas ryzyka
- Czysta regularyzacja Lasso ($l1_ratio = 1$)
- Bias-variance tradeoff ($C=1$)
- Najwyższa wartość AUC (CV): 0.8732



Regresja logistyczna

Zbiór treningowy (70%)

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
	3371	960
	2785	12830


Metryka	Wartość
Dokładność (Accuracy)	0.8122
Czułość (Recall)	0.7783
Swoistość (Specificity)	0.8216
Precyzja (Precision)	0.5476
F1 Score	0.6429
AUC	0.8744

Zbiór testowy (30%)


Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
	1445	411
	1160	5533

Metryka	Wartość
Dokładność (Accuracy)	0.8162
Czułość (Recall)	0.7786
Swoistość (Specificity)	0.8267
Precyzja (Precision)	0.5547
F1 Score	0.6478
AUC	0.8711

Regresja logistyczna -



Regresja logistyczna



Zmienna	Odds ratio
loan_grade_G	54.9836
loan_grade_F	8.9864
loan_grade_E	7.4164
loan_grade_D	6.5543
loan_percent_income	3.8806
person_home_ownership_RENT	1.8993
loan_int_rate	1.6525
person_home_ownership_OTHER	1.5183
loan_intent_HOMEIMPROVEMENT	1.1670
hist_years	1.0765
person_income	1,0391
loan_grade_C	1,0158
hist_default_in_past	1,0127
person_emp_length	1,0119
loan_grade_B	0,9148
person_age	0,8976
loan_intent_MEDICAL	0,8404
loan_intent_PERSONAL	0,5977
loan_amnt	0,5199
loan_intent_EDUCATION	0,5042
loan_intent_VENTURE	0,3080
person_home_ownership_OWN	0,1577

Pierwsze drzewo decyzyjne

Zbiór treningowy (70%)

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
Default	4331	0
Non Default	0	15615

Metryka	Wartość
Dokładność (Accuracy)	1,0000
Czułość (Recall)	1,0000
Swoistość (Specificity)	1,0000
Precyzja (Precision)	1,0000
F1 Score	0,8996
Lift (10%)	4,6063
Gain (10%)	0,4606
AUC	1,0000

Zbiór testowy (30%)

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
Default	1451	405
Non Default	502	6191

Metryka	Wartość
Dokładność (Accuracy)	0,8939
Czułość (Recall)	0,7818
Swoistość (Specificity)	0,9250
Precyzja (Precision)	0,7430
F1 Score	0,7619
Lift (10%)	3,4052
Gain (10%)	0,3405
AUC	0,8534

Pierwsze drzewo:

- Głębokość: 32
- Liczba liści: 1778

Przycięte drzewo decyzyjne

W celu przycięcia drzewa:

- wyznaczono różne wartości `ccp_alpha`
- W procesie walidacji krzyżowej AUC wyniosło 0,9058; a `ccp_alpha` = 0,000208

Głębokość przyciętego drzewa to 12,
a ilość liści to 77.

Dzięki temu model jest mniej
skomplikowany, łatwiejszy w interpretacji
i ograniczono szansę na przeuczenie

Zbiór treningowy (70%)

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
	3095	1236
	95	15520


Metryka	Wartość
Dokładność (Accuracy)	0,9333
Czułość (Recall)	0,7146
Swoistość (Specificity)	0,9939
Precyzja (Precision)	0,9702
NPV	0,9262
FDR	0,0298
F1 Score	0,8230
AUC	0,9114

Zbiór testowy (30%)

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
	1326	530
	84	6609


Metryka	Wartość
Dokładność (Accuracy)	0,9282
Czułość (Recall)	0,7144
Swoistość (Specificity)	0,9874
Precyzja (Precision)	0,9404
NPV	0,9258
FDR	0,0596
F1 Score	0,8120
AUC	0,9063

Przycięte drzewo decyzyjne



Model	Train Accuracy	Test Accuracy	Train AUC	Test AUC	Train Lift	Test Lift	Train Gain	Test Gain	Depth	Leaves	ccp_alpha
Bazowe drzewo	1.0000	0.8939	1.0000	0.8534	4.6063	3.4052	0.4606	0.3405	32	1778	0.0000
Przycięte drzewo	0.9333	0.9282	0.9114	0.9063	4.6063	4.5905	0.4606	0.4591	12	77	0.0002

Przycięte drzewo decyzyjne



Zmienna	Importance
loan_percent_income	0.302568
loan_int_rate	0.199893
person_home_ownership_RENT	0.181126
person_income	0.086239
loan_intent_MEDICAL	0.034164
loan_intent_HOMEIMPROVEMENT	0.034058
person_emp_length	0.030778
loan_grade_D	0.029965
loan_grade_C	0.026442
loan_intent_PERSONAL	0.020431
loan_intent_VENTURE	0.016123
person_home_ownership_OWN	0.011258
person_age	0.010903
loan_intent_EDUCATION	0.009347
loan_grade_G	0.004182
person_home_ownership_OTHER	0.001434
loan_amnt	0.001089
hist_default_in_past	0.000000
hist_years	0.000000
loan_grade_B	0.000000


Las Losowy

Klasa rzeczywista	Klasa predykowana	
	Default	Non Default
	Default	Non Default
	1358	39
	66	6627

Metryka	Wartość
Dokładność (Accuracy)	0,9340
Czułość (Recall)	0,7317
Swoistość (Specificity)	0,9901
Precyzja (Precision)	0,9537
F1 Score	0,8280
AUC	0,9353

Zmienna	Mean Decrease Gini
loan_percent_income	0,213942
person_income	0,141359
loan_int_rate	0,137242
loan_amnt	0,080340
person_home_ownership_RENT	0,074299
person_emp_length	0,061883
loan_grade_D	0,057003
person_age	0,048738
hist_years	0,038671
loan_intent_EDUCATION	0,016582
person_home_ownership_OWN	0,016277
loan_intent_HOMEIMPROVEMENT	0,016010
loan_grade_C	0,015889
loan_intent_MEDICAL	0,015662
loan_grade_E	0,014788
loan_intent_VENTURE	0,013380
loan_intent_PERSONAL	0,012976
hist_default_in_past	0,012221
loan_grade_B	0,004887
loan_grade_F	0,004163

Las Losowy



Support Vector Machine


Wartości zmiennych zostały zestandaryzowane, ponieważ SVM jest wrażliwy na różnice skali pomiędzy zmiennymi. Następnie wytrenowano model z jądrem RBF oraz bazowymi hiperparametrami: $C = 1$, $\gamma = \text{"scale"}$.

W kolejnym kroku przeprowadzono optymalizację hiperparametrów za pomocą GridSearchCV. Jako główne kryterium wyboru modelu przyjęto wartość AUC, ponieważ najlepiej obrazuje zdolność modelu do rozróżniania klientów defaultujących i niefaultujących.


Model	Accuracy	Recall	AUC	Lift 10%	Gain 10%
SVM bazowy	0,8835	75,43%	0,9117	4,4612	0,4461
SVM po GridSearchCV	0,8905	75,65%	0,916	4,4881	0,4488

Support Vector Machine

- Model SVM po optymalizacji osiągnął wysoką jakość predykcyjną na zbiorze testowym
- $AUC = 0,9160$ oznacza bardzo dobrą zdolność rozróżniania klientów defaultujących i niedefaultujących
- Krzywa ROC znajduje się wyraźnie powyżej linii klasyfikatora losowego, co potwierdza wysoką moc dyskryminacyjną modelu
- Model poprawnie identyfikuje 75,65% klientów defaultujących, przy zachowaniu wysokiej specyficzności na poziomie 92,77%



Porównanie modeli



- Random Forest osiągnął najwyższe AUC = 0,9353 oraz najlepsze wyniki accuracy, F1, lift i gain.
- SVM RBF bardzo dobrze rozróżnia klientów ryzykownych, osiągając AUC = 0,9160, jednak jest słabszy od Random Forest w większości metryk klasyfikacyjnych.
- Przycięte drzewo decyzyjne charakteryzuje się bardzo wysoką precyzją oraz specyficnością, co oznacza, że rzadko błędnie klasyfikuje klientów niefraudujących jako ryzykownych.
- Regresja logistyczna najlepiej identyfikuje klientów defaultujących pod względem czułości (Recall) co dla tego typu zagadnień jest najważniejszą miarą.

Model	Accuracy	MER	Recall	Specificity	Precision	F1	AUC	Lift	Gain
Best LR - Test	0.8162	0.1838	0.7786	0.8267	0.5547	0.6478	0.8711	3.7446	0.3745
Pruned Decision Tree - Test	0.9282	0.0718	0.7144	0.9874	0.9404	0.8120	0.9063	4.5905	0.4591
Random Forest - Test	0.9340	0.0660	0.7317	0.9901	0.9537	0.8280	0.9353	4.6013	0.4601
Best SVM RBF - Test	0.8905	0.1095	0.7565	0.9277	0.7436	0.7500	0.9160	4.4881	0.4488

Zysk z modeli

LGD: Uzależniony od poziomu zabezpieczenia transakcji i statusu własności nieruchomości

Mortgage: 20%

Own : 35%

Rent: 55%

Other: 65%

EAD: Definiowany jako pełna kwota wnioskowanego kredytu

$EAD = loan_amnt$

$PD < cutoff$ – wniosek zaakceptowany

$PD \geq cutoff$ – wniosek odrzucony

Przychody: (kiedy $actual_default = 0$)

Stanowi wyłącznie zebrana marża odsetkowa

$EAD \times (loan_int_rate/100)$


Koszty: (kiedy $actual_default = 1$)

Strata windykacyjna banku wynikająca z niespłaconego kapitału pomniejszonego o wartość odzyskanego zabezpieczenia

$Koszt = EAD \times LGD$

Zysk: Przychody - Koszty (dla całego portfela)

Zysk z modeli



Model	Cut-Off	Wskaźnik Akceptacji (%)
Random Forest	38.96	81.62
Pruned Decision Tree	59.38	83.90
SVM RBF GridSearch	27.57	77.44
Log Reg GridSearch	56.06	72.85

Podsumowanie

- Analiza potwierdziła, że **do najważniejszych czynników** wpływających na ryzyko defaultu należą **historia wcześniejszych problemów** ze spłatą zobowiązań, **ocena kredytowa klienta** oraz **udział kwoty kredytu w dochodzie**.
- Zbudowano i porównano cztery modele klasyfikacyjne: regresję logistyczną, drzewo decyzyjne, las losowy oraz Support Vector Machine, wykorzystując walidację krzyżową oraz optymalizację hiperparametrów.
- **Najwyższą zdolność** rozróżniania klientów spłacających i niespłacających zobowiązań **osiągnął las losowy**, uzyskując najwyższą wartość AUC spośród wszystkich analizowanych modeli.
- **Regresja logistyczna uzyskała najwyższą czułość** (Recall), dzięki czemu najskuteczniej identyfikowała klientów zagrożonych niewypłacalnością, co może być szczególnie istotne z punktu widzenia zarządzania ryzykiem kredytowym.

**Dziękujemy za
uwagę**

Bibliografia

<https://www.kaggle.com/datasets/arunbhuta/credit-analysis-probability-of-default/data>